

장애인 가구의 지급불능 상태 예측과 요인 분석
- 머신러닝 기반 모델 구축과 분석을 중심으로 -

김현우 외 3명

초록

본 연구는 장애인고용패널조사 데이터를 활용하여 장애인 가구의 지급불능(Insolvency) 상태를 예측하는 머신러닝 모델을 구축하였다. 장애인 가구는 일반 가구보다 재정적 어려움을 겪을 가능성이 높다. 기업 및 일반 가구의 지급불능 상태에 관한 연구는 많지만, 장애인 가구에 관한 연구는 상대적으로 부족하다.

본 연구는 장애인고용패널조사 2차 웨이브의 1차부터 8차까지의 데이터를 사용하였으며, 연구 대상은 경제활동을 하는 25세부터 64세의 장애인 가구이다. 지급불능 상태는 부채를 연소득으로 나눈 값인 DTI가 40%를 초과하는 가구로 정의하였다. 인구통계학적, 사회경제적, 건강, 장애, 고용 및 근로, 거시경제적 변수들을 활용하여 지급불능 상태를 예측하였다. 변수 선택은 RFE 알고리즘을 사용하였으며, 학습 과정에서는 로지스틱 회귀, 랜덤 포레스트, XGBoost, LGBM의 네 가지 모델을 활용하였다.

네 개 모델의 정확도는 79%에서 82% 사이였으며, 랜덤 포레스트 모델이 가장 높은 성능을 보였고, LGBM 모델은 성능이 상대적으로 낮았다.

연구에서 구축한 모델은 장애인 가구의 파산 위험 자가진단 애플리케이션 및 장애인 재정 위험 가구 조기 식별에 활용될 수 있다.

연구의 한계점으로는 데이터 내 특정 정보의 미포함과 결측치로 인한 샘플 수 축소가 있다.

I. 서론

파산(Bankruptcy)은 ‘채무자가 채무를 상환할 수 없는 상황’, 즉 지급불능(Insolvency) 상태가 법적으로 인정된 것을 의미한다(AJS, 2024). 국제연합 국제상거래법 위원회(UNCITRAL)는 지급불능 상태를 ‘채무자가 만기된 채무를 이행할 능력이 없는 상황’으로 정의하고 있고 이는 기업과 개인 모두에게 적용될 수 있다(UNCITRAL, 2005). 즉, 지급불능 상태는 법적인 절차를 필요로 하지 않고 채무를 이행할 수 없는 재정적 상태를 의미한다. 반면, 파산은 이러한 지급불능 상태가 공식적으로 인정되고 채무를 처리하는 과정을 의미한다.

본 연구에서는 기업이 아닌 개인의 지급불능 상황에 초점을 맞추며, 특히 장애인 가구의 지급불능 상태를 집중적으로 연구하고자 한다.

지급불능 상태인 가구들은 여러 가지 경제적 난관에 직면할 수 있다. 가구 소득 대비 높은 원리금 부담은 가계의 생활비를 줄어들게 하며, 이는 기본적인 생활 유지에 큰 어려움을 초래할 수 있다. 한국은행의 금융안정보고서에 따르면 자산매각으로도 부채를 갚지 못하거나 한 달 수익의 40% 이상을 원리금 상환에 지출하고 있는 고위험 가구의 비율이 2021년 3월 기준 2.7%(금융부채 보유 가구 대비)에서 2023년 6월 기준 5.0%로 증가했다(이정연, 2023). 지급불능 상태인 가구 수의 증가는 장기적으로 가구 소비 감소, 사회복지 비용 증가 등 사회 경제에 부정적인 영향을 미칠 수 있다.

현대 사회에서 장애인 가구는 신체 기능적 문제로 인한 노동의 어려움과 발생하는 각종 의료비용 등으로 재정적으로 취약한 계층이다(Batavia, 2001). 특히 노동시장에서 장애인은 가지고 있는 신체적 제약, 장애인에 대한 편견 등으로 인해 자산 축적에 어려움을 겪는다. 전미경제연구소(NBER, National Bureau of Economic Research)의 보고서에 따르면 노동에 지장을 줄 수 있는 만성, 중증의 장애를 가진 장애인을 10년간 추적조사 한 결과 세후 소득이 35% 감소하고, 식비 지출은 22% 감소했다고 한다(NBER, 2013). 장애인 가구는 이러한 문제들로 일반 가구보다 재정 건전성이 낮을 가능성이 높고 지급불능 상태에 빠질 수 있다. 따라서 재정적 고위험군의 장애인 가구를 선제적으로 식별하여 조치하는 것이 필요하다.

가구의 지급불능에 대한 연구는 다양한 방법으로 진행되어왔다. DeVaney(1994)는 가구의 지급불능 상태를 ‘순자산이 한 달 소득보다 적은 상태’로 정의했고, 지급불능 상태를 예측하는 지표로써 부채 대비 자산 비율, 유동성 비율²⁾ 등 재정적 비율의 유용성을 연구했다. Koro(2024)는 미시경제적 지표와 거시경제적 지표를 활용해 개인 가구

1) 총부채원리금상환비율(DSR: Debt Service Ratio)이 40% 이상인 가구와 자산 대비 부채 비율인(DTA: Debt-To-Asset ratio)이 100% 이상인 가구를 의미한다.

2) 유동자산 대비 가처분소득의 비율.

의 지급불능 상태를 예측하는 시스템을 구축하면서 환율과 같은 거시경제적 지표들이 가구 재정 상황에 미치는 영향을 연구했다. Brygala(2022)는 미국의 소비자 금융 조사(Survey of Consumer Finances) 데이터를 활용해 가구 파산에 영향을 미치는 주요 요인으로 신용 제약과 자산 대비 모기지 담보 대출 비율, 혼인 여부 등을 선정했다.

장애인 가구의 지급불능 상태에 대한 연구는 상대적으로 적게 이루어졌다. 장애인 가구의 경제적 취약성을 연구한 경우는 적지 않았지만 명확하게 장애인 가구의 지급불능 상태에 관한 연구는 매우 적었다. Beaulaurier(2001)는 장애인의 개인적 요인, 사회적 요인, 환경적 요인이 빈곤율에 미치는 영향을 연구했다. 이 연구에서는 노동 동기, 교육 수준, 그리고 기능적 결함을 소득과 빈곤율에 중요한 영향을 미치는 요인으로 선정했다. Meyer(2018)가 수행한 장애 발생 시 가구의 경제적 상황 변화 연구에 따르면, 장애 발생 10년 후 중증 장애를 가지고 있는 사람들은 77%의 소득 감소를 경험했다고 한다. 그리고 정부 및 민간보험의 지원이 장애인 가구의 재정 상황에 불완전한 지원을 하는 것으로 나타났다.

머신러닝(Machine Learning)은 기업이나 가구의 파산, 재정적 어려움을 분석하는 데에 있어 주요한 분석 도구로 활용되고 있다. 과거에 주로 사용된 통계 모델은 변수들 간의 직선적인 선형 관계를 가정했다. 하지만 현대 사회 문제, 특히 여러 요인들이 복합적으로 작용하는 사건인 파산과 같은 경우, 선형 모델로는 충분히 설명하기 어렵다. 반면, 머신러닝은 과거의 데이터를 학습하여 데이터 내 비선형적인 관계와 복잡한 패턴을 발견하는 데 강점을 가진다. 또한, 머신러닝은 방대한 양의 데이터를 처리하고 학습할 수 있어 미래 데이터의 결과값을 보다 정확하게 예측하는 데 유리하다. 특히 다년간 축적된 데이터를 활용하여 개인이나 가구의 재정적 위험을 예측하고 위험이 되는 주요 요인들을 속성중요도 분석을 통해 확인할 수 있다. 이러한 이유로 머신러닝은 기업의 재무분석이나 가구의 재정 건전성을 분석하는 필수적인 도구로 자리 잡고 있다.

장애인 가구의 재정적 위험은 단순히 소득, 지출과 같은 경제적 지표만으로 설명되지 않는다(Warren, 2023). 장애인 가구의 경우 금융 접근성, 보험 가입 여부, 의료비 등 다양한 요인들이 복합적으로 작용하여 재정 상태에 영향을 미친다. 이러한 이유로 장애인 가구의 재정적 위험은 전통적인 통계 모델로는 설명, 예측하는 데에 한계가 있다.

따라서 본 연구에서는 장애인 가구의 지급불능 여부를 예측할 수 있는 머신러닝 모델을 구축하고자 한다. 본 연구는 머신러닝을 활용하여 다양한 변수 간의 설명력을 확인하고, 특히 상대적으로 연구가 부족했던 장애인 가구의 지급불능 상태를 분석하는 데 의의가 있다. 이는 기업이나 일반 가구를 대상으로 한 기존 연구와 차별화되며, 장애인 가구의 재정적 위험을 보다 체계적으로 이해하는 데에 선행연구로써 기여할 것이다.

II. 방법론

1. 데이터 설명

본 연구는 한국장애인고용공단 고용개발원에서 진행하는 장애인고용패널조사를 사용했다. 장애인고용패널조사는 우리나라의 장애인을 대표하는 패널을 대상으로 장애인 개인의 경제활동상태를 동태적으로 파악하여 장애인의 노동시장 참여에 대한 기초자료를 제공하고 자 매년 추적조사하는 종단면 조사이다(한국장애인고용공단 고용개발원, 2024). 1차 웨이브(2008년~2015년)와 패널의 사망 등으로 인한 영구이탈, 세대 불균형 등의 문제로 새롭게 구축한 2차 웨이브(2016년~2023년)로 나누어져 있다. 2차 웨이브의 모집단은 2016년 5월 15일 기준 우리나라에 거주하는 「장애인복지법」상 등록장애인으로, 핵심 생산가능 인구를 대변할 수 있도록 만 15~64세 연령을 대상으로 하였다. 총 4577명의 패널이 구축되어 2차 웨이브의 1차 조사에 참여하였으며 태블릿PC를 이용한 대인면접조사(TAPI)를 이용해 매년 5월~8월로 1년을 주기로 조사되고 있다. 장애인고용패널조사의 조사 내용으로는 인적 특성, 장애 특성, 경제활동상태 판별, 임금근로자/비임금근로자/미취업자, 취업을 위한 노력과 지원, 직업적 능력, 취업 태도 및 환경, 일상생활과 삶의 질, 가구 일반사항 등을 담고 있다.

연구에 사용된 데이터는 2016년부터 2023년까지 시행된 장애인고용패널조사 2차 웨이브 1~8차 조사 자료이며 연구 대상의 연령은 경제활동을 하는 인구라고 판단되는 25세에서 64세로 제한하였다. 1차부터 8차까지 동일 대상을 조사하는 패널 데이터의 특징을 활용하여 시간 종속성을 고려하기 위해 long form 형태의 데이터로 사용했다. 이를 바탕으로 목표 변수로 다음 차수의 지급불능 여부를 사용하였고, 이로 인해 발생하는 결측치 데이터는 제외하고 사용했다. 결론적으로 주요 변수에 해당하는 문항에 모두 응답이 있는 3,481명을 대상으로 하여 총 16,223개의 데이터를 사용하였다. 평균적으로 한 사람당 4.66번 조사되었다.

2. 지급불능

지급불능 여부에 대해서는 DTI (Debt-to-Income)를 사용해 정의하였다. DTI는 총부채상환 비율로 월간 부채 상환액을 월 소득으로 나눈 비율을 의미한다(Consumer Financial Protection Bureau, 2023). DTI 비율이 40%를 초과하면 채무 불이행 위험이 증가한다는 선행 연구를 바탕으로 조사 데이터의 부채와 소득을 나누어 0.4를 초과할 경우 지급불능으로 0.4 이하의 경우 지급불능 상태가 아닌 것으로 정의하였다(Kim & Jin, 2020).

이 연구는 시간 종속성을 바탕으로 현재 시점의 예측변수로 미래 시점의 지급불능 여부를 예측하는 것이기 때문에 결과변수로 지급불능의 lead 변수를 사용했다. 지급불능의 lead 변수는 다음 차수의 지급불능 여부를 의미하는 변수이다.

3. Class 불균형 문제

지급불능 lead 변수의 클래스 비율을 보면 미래 시점에 지급불능 상태인 경우(지급불능 lead가 1인 경우)가 4,429개, 지급불능 상태가 아닌 경우(지급불능 lead가 0인 경우)가 11,794개이다. 각각 27.3%와 72.7%로 불균형한 것을 볼 수 있는데 특히 연구의 목표가 지급불능 상태에 해당하는 가계를 예측하는 것이기 때문에 미래 시점에 지급불능 상태인 경우의 데이터가 적은 것은 문제가 될 수 있다. 따라서 최적의 임계값을 적용하는 방법을 통해 클래스 불균형 문제를 해결하고자 한다.

4. 예측변수

본 연구에서 사용한 예측 변수 선택은 일반 가구의 지급불능에 관한 연구와 장애인 가구의 재정 상황을 연구한 선행연구를 바탕으로 하였다. 참고한 연구들에서는 나이, 성별, 지역 등 기본적인 인구통계적 변수들을 포함하고 있었다(Brygala, 2022; DeVaney, 1995; Korol, 2024).

소득과 지출 외에도 DTI, DTA, 현금성 자산, 가처분소득 등 가구의 재정적 상황을 나타내는 지표들이 분석에 활용된 것을 확인하였다(Brygala, 2022; DeVaney, 1995; Langherh, 1989; Martinez, 2013). 본 연구에서는 이러한 기본적인 사회경제적 변수와 함께, 데이터 내에서 생성 가능한 DTA, DSR, DTI, 현금성 자산, 가처분소득 등 재정적 지표들을 분석에 포함하였다.

또한, 장애인 가구의 재정 상황에 대한 선행연구에서는 중증 여부, 장애 발생 시기 등 장애 관련 변수들이 분석에 활용되었다(Batavia, 2001; Deshpande, 2019; Emerson, 2021; Meyer, 2018). 본 연구에서도 장애 발생 연령, 중증 여부, 장애 유형 등을 분석에 포함하여 장애 관련 요인들이 지급불능 상태에 미치는 영향을 고려하였다.

Korol (2024)은 가구 지급불능 상태 예측 모델을 구축할 때 GDP, 금리와 같은 거시경제 지표들이 가구 경제에 영향을 미칠 것으로 생각하여 이를 예측 변수에 포함시켰다. 본 연구에서는 FRED(Federal Reserve Economic Data)의 코스피 지수, 금리, 부동산 가격, 가계 최종 지출 등을 분석에 포함하였다.

장애인고용패널조사는 장애인의 노동시장 참여에 대한 기초자료 확보를 목적으로 시행되었기 때문에 고용과 근로 관련 정보를 많이 포함하고 있다. 이러한 고용 및 근로 관련 변수와 함께, 장애로 인한 스트레스, 자아존중감과 같은 심리적 변수도 예측 변수에 포함하였다.




그림 1. 연구 모델.

소득, 외식비와 같은 연속형 사회경제적 변수들은 로그 변환을 적용했다. 이는 변수들의 분포를 정규분포와 비슷하게 만들어 모델의 성능을 향상시키기 위함이다. 그리고 혼인상태, 학력과 같은 범주형 변수들은 모델이 데이터를 학습할 수 있도록 이진 형태(0,1)로 변환하는 원핫인코딩(One-hot encoding) 처리하였다.

총 132개의 예측변수들 중에서 모델의 가장 높은 성능을 만들 수 있는 예측변수만을 선택하기 위해 RFE(Recursive Feature Elimination) 알고리즘을 사용했다. RFE는 가장 높은 모델의 성능을 향상시키기 위해 중요하지 않은 특징을 교차 검증을 통해 반복적으로 제거한다. 이 연구에서는 XGBoost와 10겹 교차 검증을 사용하였으며 총 106개의 예측변수로 학습한 모델이 가장 높은 ROC-AUC 값을 얻었다. 표 1은 RFE 알고리즘을 통해 선택된 106개의 변수 중 연속형 변수의 기초통계량을 보여주는 표이다.

표 1은 데이터의 기초통계량을 제시한다. 주요 인구통계학적 특성은 다음과 같다. 평균 연령은 45.8세였으며, 평균 가구원 수는 2.74명이었다. 성별 분포를 보면 남성이 67.03% (10,874명)로 다수를 차지하였고, 여성은 32.97%(5,349명)이었다. 또한, 장애 구성원을 포함한 가구 비율은 9.43% (1,530개)였으며, 나머지 90.57% (14,693개)의 가구는 장애 구성원이 없는 것으로 나타났다.

표 1. 기초 통계표.

	전체 샘플 (N=16223)		Insolvency (N=4429)		No Insolvency (N=11794)	
	Mean	SD	Mean	SD	Mean	SD
성별(0,1)	0.67		0.69		0.66	
연령	45.80	9.87	45.28	9.09	45.99	10.14
가구원 수	2.74		3.05		2.62	
가구원 장애인 등록 여부(0,1)	0.09		0.09		0.10	

세대 (1-5)	3.08		3.11		3.06	
주택 크기	74.12	37.45	82.85	40.92	70.83	35.51
국민기초생활 여부(0,1)	수급 0.26		0.13		0.31	
주관적 사회 경제적 지위(1-4)	1.74		1.90		1.69	
대인관계(1-4)	2.75		2.92		2.68	
자아효능감(1-4)	2.73		2.86		2.68	
자아존중감(1-4)	2.75		2.82		2.73	
일상적 스트레스 정 도(1-5)	3.53		3.62		3.50	
행복 정도(1-10)	6.21		6.33		6.16	
만성질병 여부(0,1)	0.27		0.29		0.27	
전반적 건강 상태 (0,1)	0.54		0.62		0.52	
사회 활동 참여 여 부 (1-4)	2.24		2.34		2.20	
일상생활 만족도(1-5)	3.42		3.47		3.40	
우울증(0,1)	0.13		0.11		0.34	
음주 여부(0,1)	0.44		0.53		0.40	
흡연 여부(0,1)	0.23		0.27		0.21	
타인의 도움이 필요 한 정도(0,1)	0.31		0.23		0.34	
정기치료필요(0,1)	0.31		0.26		0.33	
장애인정책에 대한 신뢰도(1-5)	3.24		3.17		3.27	
장애인고용서비스에 대한 인식(1-5)	2.99		2.93		3.02	
장애수용정도(1-5)	3.07		3.26		3.03	
중증여부(0,1)	0.30		0.21		0.34	
장애인지연령	22.81	14.76	22.93	14.18	22.76	14.97
장애발생연령	22.44	14.89	22.52	14.38	22.41	15.08
임금근로자의 업무수 행기간(0-4)	1.27		1.48		1.19	
비임금근로자의 업무 수행기간(0-4)	0.40		0.61		0.31	
가처분소득	7.79	1.12	8.08	0.99	7.68	1.15
총지출	5.31	0.70	5.63	0.59	5.19	0.69
식비	3.89	0.54	3.98	0.54	3.86	0.54
외식비	2.15	1.20	2.45	1.12	2.03	1.21
교육비	1.08	1.73	1.64	1.93	0.86	1.60
주거비	2.86	0.62	2.99	0.59	2.81	0.63
저축	2.20	1.93	2.64	1.87	2.03	1.93
금융소득	0.15	0.96	0.14	0.94	0.16	0.97
부동산소득	0.17	1.07	0.28	1.38	0.12	0.92
연금	0.44	1.60	0.38	1.49	0.46	1.65
기초생활급여	1.56	2.76	0.75	2.06	1.87	2.92
장애인연금	0.96	1.94	0.62	1.63	1.09	2.03
원리금	1.28	2.38	3.26	2.97	0.53	1.57
자산	8.58	2.07	9.30	1.79	8.30	2.10

* N은 데이터 수, SD는 표준편차를 의미한다.

경제 변수의 경우 CPI를 이용해 데이터를 실질가치로 조정하였다.

5. 머신러닝 알고리즘

본 연구에서는 비교를 위해 로지스틱 회귀(Logistic Regression), 랜덤 포레스트(Random Forest), Extreme Gradient Boosting(XGBoost), Light Gradient Boosting Machine(LGBM)의 네 가지 예측 알고리즘을 사용하였다.

로지스틱 회귀는 결과와 예측 변수 간 선형 관계를 가정하는 예측에서 널리 사용되어 온 모델이다(Cox, 1958). 전통적인 통계적 방법으로, 복잡한 데이터에서도 해석이 간결하고 용이하다.

랜덤 포레스트는 Bootstrap Sample을 기반으로 여러 개의 결정 트리를 앙상블하고, 각 트리에서 예측된 클래스를 집계하는 트리 기반 알고리즘이다(Breiman, 2001). 랜덤 포레스트는 트리를 구축할 때 예측 변수의 랜덤 하위 공간을 고려하고, 다양한 트리 집합을 생성함으로써 분류 성능을 개선한다.

XGBoost는 Chen and Guestrin (2016)이 제안한 확장 가능한 트리 부스팅 알고리즘이다. 이 알고리즘은 약한 학습자의 예측 결과를 강한 학습자의 예측 결과와 결합하는 부스팅 아이디어에서 유래했으며, 해당 모델은 정규화, 결측값 처리, 최적화된 계산 프로세스, 높은 분류 성능 등 주로 대규모 데이터에서 탁월한 성능을 나타낸다.

LGBM은 Ke (2017)이 제안한 Gradient Boosting Decision Tree(GBDT)의 효율성과 확장성을 높이기 위한 새로운 기법들을 도입한 알고리즘으로, 메모리를 적게 차지하고 속도가 빠르다는 장점이 있다. XGBoost의 경량화된 형태로, 대규모 데이터와 높은 차원의 특성에서 학습 속도가 빠르고 메모리 사용량이 적다. 특히 Gradient-based One-Side Sampling(GOSS)와 같은 방법을 통해 효율성을 극대화시켰다. 범주형 변수들을 원핫인코딩과 같은 전처리를 거친 후 트리 계열의 모델을 사용하게 되면 모델 훈련에 시간이 많이 소요되고 과적합될 위험성이 높아지는데, 이를 대비하여 LGBM은 범주형 변수들 또한 그대로 높은 성능을 유지하여 학습이 된다는 것이 특징이다.

이 네 가지 머신러닝 알고리즘은 각기 독립적으로 훈련되었으며, 훈련 후 그 성능을 비교하여 최종적으로 성능이 가장 좋은 모델을 선택하여 활용하였다. 모든 분석은 Google Colab Python 3 CPU 가속기 환경을 사용하였다.

6. 알고리즘 설계 및 검증

본 연구에 사용된 장애인고용패널조사 데이터는 1-8차로 이루어진 설문조사 데이터로 구성되어 있다. 이에 최근 데이터가 미래 데이터를 더 잘 반영한다는 가정을 기반으로, 데이터의 일부를 미시행 데이터로 분류하고 나머지 데이터를 알고리즘 훈련에 사용함으로써 알고리즘 외부 샘플의 성능을 평가하는 데 도움을 주는 교차 검증 기법을 차용하였다.

본 연구에서는 결과변수로 조사 시기 기준 1년 후($t+1$)의 지급불능 여부를 설정하였다. 그러나 8차 조사 시기 데이터를 테스트 세트로 사용할 경우, 미래 데이터가 존재하지 않아 결과변수가 모두 결측치로 처리되는 문제가 발생한다. 이에 따라, 본 연구는 7차 조사 시기 데이터를 테스트 세트로 설정하였으며, 그 이전 조사 시기(1차-6차)의 데이터를 훈련 세트로 사용하였다.

연구에 사용된 모든 모델의 하이퍼파라미터는 5개의 무작위로 선택된 훈련 및 검증 세트에서 Grid Search를 통해 최적화되었다. Grid Search는 하이퍼파라미터의 최적값을 찾기 위해 가능한 모든 조합을 철저하게 탐색하는 조정 기법이다. 각 하이퍼파라미터 설정을 평가하기 위해 데이터는 훈련 및 검증 세트로 분할되었으며, 본 연구에서는 데이터를 동일한 크기의 5개의 무작위 폴드로 나누었다. 각 폴드는 한 번씩 검증 세트로 사용되었고 나머지 4개의 폴드는 훈련 세트로 사용되었다. 이 과정은 Grid Search CV를 통해 자동화되었으며, 모든 하이퍼파라미터 조합을 평가한 결과, 가장 높은 정확도를 나타낸 설정이 최적의 하이퍼파라미터로 선정되었다.

최적화된 설정의 로지스틱 회귀, 랜덤 포레스트, XGBoost, LGBM을 사용하여 결과변수 테스트 세트에서 지급불능 여부를 예측했으며, 최종 알고리즘의 분류 성능은 Accuracy, Sensitivity, Specificity, Balanced Accuracy, AUC, F-1 Score을 사용해 평가되었다.




그림 2. 데이터 및 모델 구조도.

Ⅲ. 결과

본 연구에서는 전처리 과정을 거친 16,223개의 관측치를 분석하였으며, DTI를 기준으로 파산여부를 예측하였다. 데이터셋의 구성 비율은 정상가구가 72.7%이고, 지급불능 상태인 가구는 27.3%였다.

RFE 알고리즘 결과, 전체 예측변수 중 모델 성능을 최대로 이끌어낼 수 있는 106개의 변수가 선택되었다. 이는 예측변수를 하나만 사용한 모델부터 모든 변수를 사용한 모델까지 비교한 결과, 106개 변수를 학습에 사용한 모델이 가장 높은 성능을 보였음을 의미한다. 106개의 주요 변수에는 성별, 가구원 수, 가구원 장애인 등록 여부, 주택 종류, 일상생활 만족도 등이 포함되었다.




그림 2. Recursive Feature Elimination 결과.

표 3. 하이퍼파라미터 튜닝 결과.

LR	regularization strength = 0, class weight = balanced, maximum number of iterations = 10, penalty for regularization = l1, solver = liblinear
RF	split rule = entropy, maximum depth of each tree = 40, number of features considered for split = log2, minimum number of samples required to split a node = 10, number of trees in the forest = 300
XGBoost	subsample ratio of columns when constructing each tree = 1.0, minimum loss reduction required to make a further partition = 0, learning rate = 0.01, maximum depth of each tree = 3, minimum sum of instance weight needed in a child = 7, number of boosting iterations = 100, subsample ratio of the training instance = 0.6
LGBM	subsample ratio of columns when constructing each tree = 1.0, learning rate = 0.01, maximum depth of each tree = 3, minimum number of data points required in a leaf = 10, number of boosting iterations = 100, subsample ratio of the training instance = 0.6

* LR, 로지스틱 회귀; RF, 랜덤 포레스트

각 머신러닝 알고리즘에 대한 최적의 하이퍼파라미터는 Grid Search 방법을 통해 얻어졌다(표 3). 로지스틱 회귀는 정규화 강도(regularization strength), 클래스가중치(class weight), 최대반복횟수, 정규화 페널티, 그리고 최적화 솔버를 기준으로 조정되었다. 랜덤 포레스트는 분할규칙(split rule), 트리의 최대깊이, 분할 시 고려되는 무작위 특성의 수, 노드 분할에 필요한 최소 샘플 수, 그리고 포레스트에 포함되는 트리의 수를 평가하여 최적의 설정을 도출했다. XGBoost는 열의 샘플 비율, 추가분할을 위해 필요한 최소 손실감소, 학습률, 트리의 최대깊이, 자식노드에서 필요한 최소 인스턴스 가중치의 합, 부스팅 반복 수, 그리고 훈련 인스턴스의 샘플 비율을 기준으로 조정되었다. LGBM은 열의 샘플 비율, 학습률, 트리의 최대깊이, 리프노드에 필요한 최소 데이터 수, 부스팅 반복 수, 훈련 인스턴스의 샘플 비율을 기준으로 설정되었다.

표 4. 알고리즘 성능.

	Logistic	RF	XGBoost	LGBM
Accuracy	0.805	0.829	0.793	0.782
Sensitivity	0.640	0.843	0.677	0.700
Specificity	0.869	0.823	0.837	0.814
Balanced accuracy	0.754	0.833	0.757	0.757
AUC	0.827	0.907	0.825	0.822
F-1 score	0.645	0.732	0.644	0.641

* LR, 로지스틱 회귀; RF, 랜덤 포레스트

표 4는 지급불능 여부를 예측하는 네 가지 머신러닝 알고리즘의 테스트 세트 분류 성능을 제시한다. 랜덤 포레스트는 0.829의 정확도(Accuracy)를 보이며 가장 뛰어난 성능을 기록했고, 다음으로 로지스틱 회귀(0.805)와 XGBoost(0.793)가 뒤를 이었다. LGBM은 0.782로 상대적으로 낮은 정확도를 보였다.

민감도(Sensitivity) 지표에서 랜덤 포레스트는 0.843을 기록하였으며, 이는 실제 지급불능 상태인 가구 중 84.3%를 모델이 정확히 파산으로 예측했음을 의미한다. 반면 XGBoost와 LGBM은 각각 0.677과 0.700, 로지스틱 회귀는 0.640으로 상대적으로 낮은 민감도를 보였다.

특이도(Specificity)는 로지스틱 회귀가 0.869로 가장 높은 값을 기록했으며, 이는 정상 가구를 가장 잘 구분했다는 의미다. 랜덤 포레스트는 0.823, XGBoost는 0.837, LGBM은 0.814를 기록했다.

균형 정확도(Balanced Accuracy)는 랜덤 포레스트가 0.833으로 가장 높았고, XGBoost와 LGBM은 각각 0.757로 동일한 성능을 보였다. 교차검증된 AUC는 랜덤 포레스트가 0.907로 가장 높은 값을 보였다.

그림 3은 네 가지 머신러닝 알고리즘의 ROC Curve를 보여준다.




그림 3. 네 가지 알고리즘의 ROC Curve.

랜덤 포레스트는 AUC 값이 0.91로 가장 높게 나타났으며, 이는 지급불능 상태를 예측하는데 탁월한 성능을 보여주었다. 반면 로지스틱 회귀는 0.83, XGBoost와 LGBM은 각각 0.82로 나타나 상대적으로 근소한 차이를 보였다.

전반적으로 랜덤 포레스트는 정확도, 민감도, AUC 등 다양한 성능지표에서 가장 우수한 결과를 보이며 지급불능 여부를 예측하는데 가장 효과적인 알고리즘으로 확인되었다.

지급불능 여부를 정의할 수 있는 방법은 다양하기 때문에, 본 연구에서는 DTI와 더불어 DTA 및 Emergency Fund(현금 비상자금 비율)를 기준으로 실험을 추가적으로 수행하였다. DTA는 자산 대비 부채 수준이 100% 초과일 경우, Emergency Fund는 현금성 자산이 월 평균 지출의 6배보다 적을 경우 지급불능 상태로 정의하여 분석하였다.

표 5. DTA 기준 최적화된 하이퍼파라미터.

LR	regularization strength = 0.01, class weight = balanced, maximum number of iterations = 100, penalty for regularization = l2, solver = saga, random state = 1225
RF	split rule = gini, maximum depth of each tree = 20, number of features considered for split = sqrt, minimum number of samples required to split a node = 2, number of trees in the forest = 200, random state = 1225
XGBoost	subsample ratio of columns when constructing each tree = 1.0, minimum loss reduction required to make a further partition = 0.2, learning rate = 0.1, maximum depth of each tree = 3, minimum sum of instance weight needed in a child = 7, number of boosting iterations = 100, subsample ratio of the training instance = 0.6, random state = 1225
LGBM	subsample ratio of columns when constructing each tree = 1.0, learning rate = 0.1, maximum depth of each tree = 7, minimum number of data points required in a leaf = 30, number of boosting iterations = 100, number of leaves = 70, subsample ratio of the training instance = 0.6, random state = 1225

* LR, 로지스틱 회귀; RF, 랜덤 포레스트

표 6. Emergency Fund 기준 최적화된 하이퍼파라미터.

LR	regularization strength = 0.1, class weight = balanced, maximum number of iterations = 500, penalty for regularization = l2, solver = saga, random state = 1225
RF	split rule = entropy, maximum depth of each tree = 20, number of features considered for split = log2, minimum number of samples required to split a node = 20, number of trees in the forest = 500, random state = 1225
XGBoost	subsample ratio of columns when constructing each tree = 0.8, minimum loss reduction required to make a further partition = 0, learning rate = 0.01, maximum depth of each tree = 3, minimum sum of instance weight needed in a child = 3, number of boosting iterations = 100, subsample ratio of the training instance = 0.8, random state = 1225
LGBM	subsample ratio of columns when constructing each tree = 0.8, learning rate = 0.01, maximum depth of each tree = 3, minimum number of data points required in a leaf = 30, number of boosting iterations = 100, number of leaves = 31, subsample ratio of the training instance = 0.6, random state = 1225

* LR, 로지스틱 회귀; RF, 랜덤 포레스트

표 7. DTA 기준 알고리즘 성능.

	Logistic	RF	XGBoost	LGBM
Accuracy	0.314	0.900	0.741	0.867
Sensitivity	0.865	0.833	0.885	0.844
Specificity	0.292	0.903	0.735	0.868
Balanced accuracy	0.578	0.868	0.81	0.856
AUC	0.557	0.925	0.883	0.914
F-1 score	0.09	0.388	0.206	0.325

* LR, 로지스틱 회귀; RF, 랜덤 포레스트

표 7은 DTA를 기준으로 지급불능 여부를 예측한 네 가지 머신러닝 알고리즘의 성능을 제시한다. 랜덤 포레스트는 0.900의 정확도와 0.925의 AUC를 기록하며 가장 우수한 성능을 보였다. 그 다음으로 LGBM(0.867)과 XGBoost(0.741)가 뒤를 이었고, 로지스틱 회귀는 0.314로 상대적으로 낮은 정확도를 기록하였다.

표 8. Emergency Fund 기준 알고리즘 성능.

	Logistic	RF	XGBoost	LGBM
Accuracy	0.626	0.763	0.703	0.702
Sensitivity	0.835	0.875	0.768	0.762
Specificity	0.579	0.737	0.688	0.689
Balanced accuracy	0.707	0.806	0.728	0.725
AUC	0.762	0.878	0.793	0.793
F-1 score	0.452	0.577	0.490	0.486

* LR, 로지스틱 회귀; RF, 랜덤 포레스트

표 8은 Emergency Fund를 기준으로 지급불능 여부를 예측한 네 가지 머신러닝 알고리즘의 성능을 보여준다. 랜덤 포레스트는 0.763의 정확도와 0.878의 AUC를 기록하며 가장 우수한 성능을 보였다. LGBM(0.702)과 XGBoost(0.703)는 유사한 정확도를 보였으며, 로지스틱 회귀는 0.626로 가장 낮은 정확도를 기록하였다. DTA와 Emergency Fund 기준 실험 결과를

비교하면, 두 기준 모두에서 랜덤 포레스트가 가장 우수한 성능을 보였다는 공통점이 있다.

DTA와 Emergency Fund를 기준으로 추가 실험을 수행하며, 각 결과변수에 따른 모델 성능 차이를 비교하였다. 이는 지급불능 정의 방식에 따라 모델 성능이 다르게 나타날 수 있음을 보여준다.

IV. 논의

장애인 가구의 지급불능 상태나 재정적 상황에 대한 연구에서 중요한 것은 경제적 지표 뿐만 아니라 심리적, 사회적, 제도적 요인을 포함한 다양한 변수들의 영향을 함께 고려하는 것이다. 따라서 예측 모델을 구축할 때 변수 선택 알고리즘을 활용하여 가처분소득이나 총지출과 같은 경제적 변수 외에도 자아존중감, 장애연금, 직업 만족도 등 다양한 심리적 및 사회적 변수를 추가하였다. 그리고 물가와 같은 거시경제적 지표들이 결과에 미치는 영향을 고려하여, 실업률, 금리, 가계 총지출 등과 같은 변수를 추가적으로 포함하였다.

본 연구에서는 장애인고용패널조사 데이터를 활용하여 결과변수인 지급불능 여부를 예측하는 머신러닝 모델을 구축하였다. 로지스틱 회귀, 랜덤포레스트, XGBoost, LGBM 총 4가지 모델들을 학습에 사용하였다.

4가지 모든 알고리즘에서 78%에서 82%의 정확도의 분류 성능을 확인할 수 있었다. 그 중 결과가 가장 좋은 알고리즘은 랜덤 포레스트 모델로 82.9%의 정확도, 84.3%의 민감도를 보였고, AUC 점수는 0.97을 기록했다.

본 연구에서 구축한 예측 모델은 장애인 가구를 대상으로 한 온라인 설문 작성이나 장애인 가구 재정 위험 자가 진단 애플리케이션 개발에 활용될 수 있다. 장애인 가구는 다양한 측면에 대한 답을 하면서 자신이 지급불능 위험에 처한 가구인지를 사전에 식별하고, 전략을 수립하거나 기관에 도움을 요청할 수 있을 것이다. 장애인 복지 정책을 입안하는 기관 또한 본 예측 모델을 활용하여 효과적인 장애인 지원 방안을 마련할 수 있을 것이다.

연구를 진행하면서 몇 가지 한계점이 존재했다. 첫 번째는 데이터에 구체적인 금융 관련 정보가 없었다는 점이다. 데이터 내 예금 저축액, 대출 상환 연체 여부와 같은 재정 상황을 나타낼 수 있는 구체적인 금융 정보가 포함되지 않아 실효성 있는 분석에 한계가 있었다.

두 번째 한계점은 모델 학습에 활용할 수 있는 노동 관련 변수의 부족이다. 데이터 내 노동 관련 질문이 임금근로자, 비임금근로자, 미취업자별로 다르게 구성되어 있어, 모델에 활용된 노동 관련 변수는 공통 질문 4개 정도에 그쳤다.

마지막 한계점은 데이터 내 결측치로 인한 샘플 수 감소이다. 사용한 데이터가 패널 데이터이다 보니 응답자가 한 가지 문항에만 응답을 안 하더라도 분석에 사용할 수 없게 된다. 그리고 1차 조사부터 8차 조사까지 빠지지 않고 응답한 조사자 수가 꽤 적었고 조사 미참여자로 인한 결측치도 많았다.

이러한 한계점들의 영향으로 구축한 모델은 실제로 활용할 만큼 분류 성능이 뛰어나지 못했다. 분류 성능이 뛰어나지 못했다는 것은 모델의 예측변수들이 결과변수의 변동을 충분히 설명하지 못했다는 것을 의미한다. 앞서 언급했듯 데이터 내 설명력 높은 예측변수 부족, 결측치로 인한 샘플 수 감소 등이 영향을 미쳤을 것으로 예상된다. 이러한 한계점을 극복하기 위해 향후 비슷한 연구를 진행한다면 뉴스 기사, 금융상품 리뷰, 정책 리뷰 등의 비정형 데이터를 예측변수에 포함하여 모델의 결과변수에 대한 설명력을 높일 수 있도록 할 것이다.

참고문헌

- 김영도, & 김진성. (2020). 주택담보대출에서 연체 및 채무불이행의 발생시기별 위험률: DTI와 LTV 비율의 교차 효과를 중심으로. *한국금융학회지*, 34(3), 25-48.
- Batavia, A. I. (2001). The financial vulnerability of people with disabilities: Assessing poverty risks. *Journal of Sociology & Social Welfare*, 28(1), 140.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.
<https://doi.org/10.1023/A:1010933404324>
- Meyer, B. D. (2018). Disability, earnings, income, and consumption. *Journal of Public Economics*, 171, 52-69.
- Bengali, L., Daly, M. C., & Valletta, R. G. (2021). The economic status of people with disabilities and their families since the Great Recession. *Federal Reserve Bank of San Francisco Economic Letter*.
<https://www.frbsf.org/economic-research/publications/economic-letter/2021/>
- Brygala, M. (2022). Consumer bankruptcy prediction using balanced and imbalanced data. *Mathematics*, 10(1), 1-12. <https://doi.org/10.3390/math10010012>
- Chetty, R., Friedman, J. N., Leth-Petersen, S., Nielsen, T. H., & Olsen, T. (2013). Do retirement savings policies increase total retirement saving? *NBER Working Paper Series*. <https://doi.org/10.3386/w19063>
- DeVaney, S. A. (1994). The usefulness of financial ratios as predictors of household insolvency: Two perspectives. *Journal of Financial Counseling and Planning*, 5(1), 9-18.
- DeVaney, S. A. (1995). Household insolvency: A review of household debt repayment, delinquency, and bankruptcy. *Financial Services Review*, 4(2), 138-147.
- Korol, T. (2021). Evaluation of the macro- and micro-economic factors affecting the financial energy of households. *Energies*, 14(1), 3-6. <https://doi.org/10.3390/en14010003>
- Korol, T. (2021). Examining statistical methods in forecasting financial energy of households in Poland and Taiwan. *Energies*, 14(1), 6-8. <https://doi.org/10.3390/en14010006>
- Korol, T. (2024). Multi-factor fuzzy sets decision system forecasting consumer insolvency risk. In *Advances in Fuzzy Systems* (pp. 282-288). Springer.
https://doi.org/10.1007/978-3-031-12462-4_31
- UNCITRAL. (2005). *Legislative guide on insolvency law*. United Nations Commission on International Trade Law (UNCITRAL).
- Langehr, V. B. (1989). Measuring the ability to repay: The residual income ratio. *Journal of Consumer Affairs*, 23(2), 385-389.
- 장애인고용패널조사. (2024). Retrieved December 17, 2024, from https://edi.kead.or.kr/Contents.do?cmd=_051A&mid=213.
- Bankruptcy vs. insolvency: Making sense of financial distress. (2024). Retrieved December 17, 2024, from <https://www.ajs.org/making-sense-of-financial-distress/>.
- Consumer Financial Protection Bureau. (n.d.). What is a debt-to-income ratio? Retrieved December 17, 2024, from <https://www.consumerfinance.gov/ask-cfpb/what-is-a-debt-to-income-ratio-en-1791/>

- LightGBM Documentation Team. (n.d.). Parameter tuning. Retrieved December 17, 2024, from <https://lightgbm.readthedocs.io/en/latest/Parameters-Tuning.html>.
- Poslavskaya, E., & Korolev, A. (2023). Encoding categorical data: Is there yet anything 'hotter' than one-hot encoding? *Data Science Trends*, 5(3), 45–58.
- Zhu, J., Wang, S., & Wang, Y. (2007). Enhanced recursive feature elimination. In *Proceedings of the 22nd International Conference on Machine Learning* (pp. 437–442). ACM. <https://doi.org/10.1145/1273496.1273540>