

TFT-LGBM 하이브리드 모델을 활용한 범정부 단위 119 신고 수요 예측

공모분야: 소방데이터와 날씨 빅데이터를 융합한 119 신고 건수 예측 **참가번호:** 250587 **팀명:** 성균갈매기

1. 분석 배경 및 목표

1) 분석 배경

도시의 안전은 시민의 삶의 질과 직결되는 핵심 요소이며, 119 긴급출동 시스템은 그 최전선에 있다. 특히, 복잡한 지리적·사회적 특성을 가진 부산광역시와 같은 대도시에서는 한정된 응급 자원(구급차, 소방 인력 등)을 효율적으로 배분하는 것이 매우 중요하다. 실제로 구급 서비스의 수요와 공급은 부산광역시의 행정구역 간 뚜렷한 차이를 보이며, 특정 행정구역에 서비스가 집중되거나 부족한 현상이 나타난다(이달별, 2020). 여기에 집중 호우와 같은 기상이변은 도로 통제나 현장 도착 지연 등을 초래하여 이러한 불균형을 더욱 심화시킬 위험이 있다(이달별, 2020). 부정확한 수요 예측은 자원의 낭비 또는 골든타임 확보 실패라는 치명적인 결과로 이어질 수 있다. 본 분석은 119 신고 데이터에 내재된 복잡한 시공간적 패턴과 리스크 요인을 정량적으로 분석하여, 데이터 기반의 예측-운영 체계 고도화를 구축하는 것이 시급한 과제로 부각되고 있다.

2) 분석 목표

본 과제는 다음과 같은 목표를 가지고 수행되었다.

가. 고성능 예측 모델 구축: 부산광역시 범정부 단위의 일별 119 신고 건수를 대상으로, 다양한 외부 요인을 통합한 딥러닝 기반 예측 모델을 개발하고자 한다. 예측 정확도(RMSE)를 주요 성능 지표로 설정하고, 실용화 가능 수준(0.8 이하)을 목표로 하여 실제 행정 현장에서 활용할 수 있게 하는 것을 목표로 한다.

나. 위험 요인 해석 및 정량화: 단순한 예측을 넘어 신고 건수에 영향을 미치는 핵심 요인을 식별하고, 각 요인이 리스크에 미치는 영향을 정량적으로 분석한다.

다. 정책·실무 적용 가능한 활용 방안 제시: 분석 결과를 기반으로 신고 위험도 수준을 시공간적으로 시각화한 ‘119 리스크 맵’을 제작하고, 이를 통해 고위험 지역 사전 탐지, 선제적 인력 배치, 출동 전략 최적화 등 응급 대응 자원 운영 전반에 활용할 수 있는 방안을 제안하고자 한다.

궁극적으로 본 분석은 단순한 기술적 모델링을 넘어서 정책적 개입의 기준점과 현장 실무 대응력 강화를 동시에 추구하는 데이터 기반 의사결정 지원 체계 수립을 목표로 한다.

2. 분석 데이터 및 전처리

제공된 기상 데이터 외에 외부 데이터를 추가 수집하고 파생 변수를 생성하여, 최종적으로 99,360행 70열의 데이터셋을 구축하였다.

표1. 전체 데이터셋

범주	개수	변수	범주	개수	변수
Target	1	call_count	도시환경	7	turnel_count, underpass_count, hw_count, mroad_count, road_count, 행정기관수, hospital
시간	7	tm, is_weekend, is_holiday, month_sin, month_cos, day_sin, day_cos	공간	7	address_gu, sub_address, stn, lat, lon, address_gu_encoded, sub_address_encoded
관광·휴양	3	규모(제공미터), 방문자수(천명), 해수욕장 유무	방역	2	확진자수, 사망자수
기상	11	ta_max, ta_min, ta_max_min, hm_min, hm_max, hm_min_max, is_rain, ws_max, ws_ins_max, rn_day, is_rain_cont	소방자원	11	center119, center119_면적, center119_인구, center119_소방관, center119_1인당인구, fire_station, fire_station_면적, fire_station_인구, fire_station_세대, fire_station_인력, fire_station_차량
인구	5	총인구, 0-14세 인구, 65세 이상 인구, 남자인구수, 여자인구수	세부신고/통계	16	*업무운행, *업무운행_mean(all), *업무운행_mean(year), *업무운행_mean(month), *구급기타, *구급기타_mean(all), *구급기타_mean(year), *구급기타_mean(month), *산악-수난, *산악-수난_mean(all), *산악-수난_mean(year), *산악-수난_mean(month), *기타2, *기타2_mean(all), *기타2_mean(year), *기타2_mean(month)

1) 외부 데이터 수집 및 전처리

가. 인구

지역별 인구 구조는 신고 건수에 영향을 미치는 중요한 요인 중 하나로 고려되었다. 해당 변수들은 KOSIS에서 제공하는 인구 데이터를 기반으로 산출했으며, 2020~2024년의 월별 자료를 수집했다. 원본 데이터는 연도별, 행정동별, 성별 및 5세 단위 연령별 인구수로 구성되어 있으며, 이를 연령대 및 성별로 집계했다. 또한, 해당 데이터는 행정동 기준으로 집계되어 제공되므로, 본 분석에서 활용하는 법정동 단위와의 불일치를 해소하기 위해 행정안전부 자료를 기반으로 법정동-행정동 매핑 작업을 수행했다.

나. 도시환경

- **행정기관**: 구청, 주민자치센터, 문화회관, 도서관 등 관내 행정기관의 분포는 해당 지역의 인프라 밀집도 및 유동인구 규모와 밀접한 관련이 있으며, 이는 119 신고 건수에도 영향을 미친다. 특히, 공공 시설의 집중도는 평시·비상시 모두 시민 접촉이 잦은 공간이라는 점에서, 구조·구급 수요 발생 가능성과의 관련성이 있다. 각 기관별 주소 정보를 법정동 단위로 일괄 변환하여 지역 단위를 통일하였다. 주소 변환 시 행정안전부의 공식 행정구역 데이터를 활용하여 각 법정동별 행정기관 수를 집계하였다.

- **교통**: 교통사고 관련 신고 건수가 다른 유형에 비해 두드러지게 많았기 때문에 도로 인프라와 신고 건수의 관련성을 파악하고자 고속도로, 대로, 로의 개수와 지하차도, 터널의 개수를 변수로 추가했다. 해당 변수들은 부산광역시 도로구간조서 및 지하차도, 터널 현황 데이터를 기반으로 구축했으며, 주소 정보를 법정동 단위로 변환한 후 각 동별로 포함된 도로 및 지하차도와 터널 개수를 집계했다.

- **병원**: 종합병원은 응급 상황 발생 시 주요 이송 대상이 되므로, 병원의 규모가 클수록 구조·구급 관련 신고 건수와의 연관성이 높을 것으로 판단되어 분석 변수로 포함하였다. 해당 변수는 공공데이터포털에서 제공하는 부산광역시 종합병원 현황 데이터를 활용하였으며, 각 법정동 내 병상 수를 기준으로 병원의 규모를 나타낸다. 하나의 동에 두 개 이상의 병원이 위치한 경우에는 병상 수를 합산하여 해당 동의 총 병상 수로 활용하였다.

다. 관광·휴양

여름철 관광 인구의 유입이나 계절성 이벤트로 인한 신고 건수 증가와 같은 현상을 설명하기 위해, 해수욕장 관련 데이터를 수집하였다. 부산광역시의 해수욕장 방문 현황 데이터를 활용하여, 2020년부터 2024년까지의 개장 및 폐장 일자에 맞춰 데이터를 통합하였다. 이 과정에서 해양수산부의 해수욕장 일정 및 현황 데이터를 이용하여 해수욕장의 법정동 정보를 매핑하였다.

라. 코로나19

연도별 신고 건수의 차이가 있음을 확인했으며, 특히 Covid 19의 유행이 시작되었던 2020년에 신고 건수가 전반적으로 높게 나타났다. 따라서 월별 코로나19 확진자 및 사망자 발생현황 데이터를 수집하였다. 해당 데이터는 질병관리청 공식 통계를 기반으로 하며, 각 월별로 시군구 단위의 확진자 수 및 사망자 수를 집계했다. 2023년 9월 이후로는 정부 차원의 집계 중단됨에 따라, 이후 기간에 대해서는 결측값으로 처리하였다.

마. 소방자원

법정동 내 소방서 및 119 안전센터의 수가 많을수록 신고 건수가 증가할 가능성이 있으며, 함께 관련 업무의 증가로 이어져 업무운행에 해당하는 신고 건수 또한 늘어날 것으로 판단된다. 실제로 EDA 과정에서 업무운행이 신고 건수에 약 15%를 차지하는 것이 확인되었다. 이에 따라 소방서 및 119 안전센터의 개수와 규모를 나타내는 변수를 생성하였으며, 해당 정보는 부산광역시 소방재난본부 홈페이지의 일반현황 데이터를 기반으로 수집하였다. 수집된 데이터에서 소방서의 면적, 인구, 세대 수는 관할 구역 정보를, 인력과 차량 수는 소방대원 수와 소방 차량 수를 각각 의미한다. 119 안전센터의 면적, 인구는 관할 구역 정보를 의미한다. 만약, 하나의 법정동 내에 두 개 이상의 119 안전센터가 존재하는 경우, 합산하는 방식을 통해 법정동 내 안전센터의 규모를 나타냈다.

2) 탐색적데이터분석 (EDA)

가. 일별 결측 현황

표2. 변수별 결측 현황

변수명	결측 행 수	결측률(%)	변수명	결측 행 수	결측률(%)
hm_min	652	0.082	ws_max	28	0.004
hm_max	652	0.082	ta_max	26	0.003
rn_day	42	0.005	ta_max_min	26	0.003
ws_ins_max	28	0.004	ta_min	26	0.003

- **풍속 변수 결측(태풍 영향 가능성):** ws_max와 ws_ins_max의 결측 간 상관계수가 0.96으로 강한 동조를 보였다. 두 변수가 거의 동시에 결측이 발생함을 의미한다.

- **습도 변수 결측:** hm_min · hm_max는 항상 동시에 결측이 발생한다. 이 두 변수의 결측과 다른 기상 변수 결측 간 상관계수는 0.14 ~ 0.18 수준으로 낮으며, 풍속 결측과의 상관도 0.18에 불과하다. 따라서 습도 결측은 태풍(강풍)이나 타 변수 결측과 별개로 발생한다고 볼 수 있다. 실제로 결측 652행 중 96% 이상이 습도 두 변수만 단독으로 결측이었으며, 이는 센서 단일 고장 가능성을 시사한다.

- **공간적 집중:** 습도 결측의 80.4%가 세 관측소(stn 938, 941, 942)에 집중됐고, 이들 관측소에서는 최소 1개월 이상 지속되는 장기 결측 구간이 확인됐다. 이는 센서 고장(외부 오염, 결로, 노후화)과 2020년 Covid19로 인한 현장 점검 · 부품 교체 지연이 겹쳐 발생한 것으로 보인다. 해당 관측소는 결측 보간 시 특히 주의해야 할 것이다.

나. 신고 건수 분포 및 기초통계량 확인




그림1. 연도별 일별 신고 건수

연도별 일별 신고 건수를 시계열로 그리면 공통으로 8-9월, 즉 태풍이 접근하는 시기에 급격한 단기 급등이 나타난다. 2020년 곡선은 특히 두드러져서 최고 2,334건까지 치솟는 극단값이 포함되며, 같은 해 다른 날들의 50-150건 수준과 대비된다. 전체 2020-2023 데이터를 합쳐 집계한 기초통계량은 평균 112건, 25-75% 사분위가 89-117건으로 비교적 안정적이지만 표준편차가 93건으로 평균에 근접해 분산이 크다는 점, 최대값이 2,334건에 달한다는 점에서 강한 이상치 영향이 확인된다. 연도별로 보면 2020년 표준편차가 176건으로 다른 해 대비 두 배 이상 높고 사분위 범위 역시 넓다. 이는 2020년에 집중호우 및 태풍이 겹친 8-9월에 긴 꼬리 분포를 형성했기 때문이다. 반면 2021-2023년에는 유사한 시기에 스파이크가 존재하지만 규모가 350-500건 선으로 상대적으로 작고 평상시 변동 폭도 50-200건 사이로 좁다. 요약하면, 매년 태풍 시점에 신고 건수가 급증하는 공통 패턴이 있으나 2020년에는 극단적인 이상치가 집중되어 전체 분산을 크게 왜곡하고 있어 별도 처리 혹은 주의가 필요하다.

다. 업무운행 관련

신고 건수 상위 0.5%에 해당하는 행만 추출해 sub_cat의 비율을 계산한 결과, 자연재해 69.4%, 업무운행 15.4%, 부상 8.0%, 지원출동(풍수해) 3.4% 순으로 집중돼 있었다. 이 가운데 업무운행은 실제 긴급 출동이 아니라 소방 조직 내부의 업무 이동을 집계한 건수임을 확인했으며, 이러한 조직 활동을 설명할 수 있도록 119 안전센터 수 등의 행정 인프라 데이터를 추가해 모델에 반영했다.

3) 파생변수 생성

기존 변수만으로는 드러나지 않은 잠재적 요소를 명확히 드러내고자 다양한 파생변수를 생성했다.

가. 시간 변수 기반 파생변수

신고 건수는 요일, 공휴일, 계절 등 시간적 요인에 따라 달라질 수 있다는 점에서 시간 관련 파생변수를 생성했다. 단순한 날짜 정보 대신 시간의 순환성과 맥락을 반영하고자 주말, 공휴일 여부와 같은 이진 변수와 함께 월(month)과 일(day)을 주기 함수인 사인(sin), 코사인(cos)으로 변환한 변수를 도출했다. 이러한 변환은 1월과 12월처럼 연속적이지만 수치상 떨어진 값을 모델이 유사하게 인식할 수 있도록 하며, 계절성과 날짜 주기성을 반영하여 신고 건수의 시계열적 변동을 정밀하게 학습하는 데 기여했다.

나. 기상 변수 기반 파생변수

기온과 습도는 사건 발생과 밀접한 관련이 있다는 점에 착안하여, 이들 간의 상호작용을 반영한 파생변수를 생성하였다. 일반적으로 온도가 높을수록 공기 중 포화 수증기량이 증가하여 습도가 높아지고, 온도가 낮을수록 습도가 낮아지는 경향이 있다는 기상학적 특성을 바탕으로 최고 습도와 최저 습도의 차이를 활용한 습도차 변수를 도출하였다. 분석 결과, 해당 변수는 일교차와 0.78의 높은 상관관계를 보여 기상 조건의 복합적인 영향을 효과적으로 설명할 수 있는 지표로 활용될 수 있었으며, 이는 모델의 예측 정밀도 향상에 기여할 수 있는 요소로 판단되었다.

다. 신고 종류 기반 파생변수

신고 건수는 행정구역별로도 차이가 있지만, 신고 종류별로도 발생 빈도와 특성이 크게 다르다는 점에 주목했다.

초기에는 전체 신고 건수에 대해 평균, 표준편차 등 통계량을 활용해 행정구역별 특성을 요약하고자 했으나, 신고 유형의 다양성으로 인해 대표성이 떨어지는 한계를 확인했다. 이에 유사한 신고 종류들을 네 개의 그룹으로 분류한 뒤, 각 그룹별로 행정구역 단위의 연평균 및 월평균 신고 건수를 계산하여 파생변수로 생성했다. 이러한 방식은 신고의 성격을 반영함과 동시에 지역별 특성을 정교하게 반영할 수 있어 모델의 설명력을 높이는 데 효과적이었다.

24개의 신고 종류는 의미적 유사성, 신고 간 동시 발생 빈도, 그리고 전체 신고 건수에 대한 예측 정확성을 기준으로 네 개의 그룹으로 분류되었다. 먼저, ‘구급’으로 분류된 ‘교통사고’ 신고 항목과 ‘구조’로 분류된 ‘교통사고’ 신고 항목의 경우 그 의미가 유사하기 때문에 하나의 신고 항목으로 그룹화를 진행했다. 이러한 방식으로 두 개의 항공 관련 신고 항목과 일곱 개의 지원출동 관련 신고 항목을 각각 그룹화하였다. 이후, ‘자연재해’ 신고 항목과 ‘지원출동’ 신고 항목의 동시 발생 빈도가 높다는 점에 근거하여 하나의 신고 항목으로 그룹화하였다. 이렇게 구성된 각 신고 항목 그룹을 무작위로 그룹화하며 신고 건수를 예측하며 RMSE를 측정하는 과정을 반복하였고, 최종적으로 예측 정확도가 가장 높은 네 개의 그룹으로 최적화된 분류를 완성했다.

4) 결측치 보간

가. 단기 결측 (30일 미만)

기온은 지표면에서 완만하게 변한다는 기상학적 특성을 고려하여 물리적 거리가 가까운 세 관측소의 평균값과 유사함을 확인했다. 반면 풍속과 습도는 지형과 바람길 영향으로 요동이 커서, 오차를 줄이려면 값을 다섯 곳까지 모아 평균하는 편이 안정적이다. 강수량은 한 구름이 내리는 범위가 좁고 ‘내리는 곳만 내리는’ 성격이 강해 너무 많은 관측소를 섞으면 실제 비를 희석해 버리므로, 가장 가까운 세 곳만 참고하기로 결정했다. 이에 따라, 각 방재기상관측(AWS) 관측소에서 결측된 데이터를 보간할 때, 변수별로 유사도가 높은 관측소를 사전에 정의하고 해당 유사 관측소들의 평균값으로 결측을 보간하였다. 구체적으로 기온 관련 변수(ta_max, ta_min, ta_max_min)은 유사 관측소 3곳의 평균값으로, 풍속 관련 변수(ws_max, ws_ins_max)는 유사 관측소 5곳의 평균값으로, 습도 관련 변수(hm_min, hm_max)는 유사 관측소 5곳의 평균값으로, 강수(rn_day)는 유사 관측소 3곳의 평균값으로 보간했다.

나. 장기 결측 (30일 이상)

30일 이상의 연속된 결측 구간을 가지는 습도 변수(hm_min, hm_max)의 경우 랜덤포레스트 회귀 모델을 활용하여 결측 구간을 1차로 예측했다. 이렇게 얻은 1차 예측값은 관측소별 계절성, 기온·풍속 효과와 같은 대규모 패턴을 반영한다. 각 관측소에서는 실측값에서 1차 예측값을 뺀 잔차를 계산하고, 날짜별로 모아 잔차의 공간적 상관구조를 변동함수(variogram)로 추정했다. 변동함수는 ‘거리가 가까운 관측소일수록 잔차가 비슷하다’는 경향을 수량화해 거리에 따라 가중치를 조정하는데, 이를 바탕으로 크리깅(ordinary kriging)을 적용해 잔차가 없는 지점의 잔차를 최소 분산 추정치로 보간했다. 이렇게 얻은 잔차 예측값을 1차 모델 예측치에 더해 결측 지점의 습도를 최종적으로 보정했다. 이때, 값 그대로를 크리깅하지 않고 잔차만 보간하는 이유는 회귀모델이 이미 잡아준 계절성·시간 변화·대기환경 같은 큰 흐름을 다시 공간 보간이 중복해서 학습하는 것을 막고, 모델이 설명하지 못한 지형·노출·국지풍 같은 미세 공간효과만 추가하기 위함이다. 결과적으로 1차 예측이 제공하는 전역적 안정성과 잔차 크리깅이 더해주는 지역 세밀성이 합쳐져, 높은 신뢰도를 바탕으로 결측값을 보간할 수 있었다. 아래의 그림은 부산광역시 북구의 STN(941)에 대해 2021년의 최저 습도(hm_min)를 인위적으로 마스킹한 뒤 보간한 값과 실제 값을 비교한 도표이다. 이를 통해 보간한 값이 시간의 흐름에 따른 실제 값의 변화를 잘 반영하고 있다는 것을 알 수 있다.




그림 2. 장기 결측 보간 결과

5) 연속 시계열 구축

주어진 call119 데이터의 경우 신고 건수가 0인 행은 제거된 상태였다는 점을 고려하여 전체 기간동안 모든 행정구역의 데이터가 누락 없이 모두 존재하도록 신고 건수가 0인 행을 추가하여 연속 시계열 데이터를 구축했다. 이때, 기존의 데이터에 존재하지 않는 행을 생성하기 위해 날씨 변수들의 값은 기상청 API 허브의 AWS API를 활용했다.

3. 분석 방법

1) 분석 모델

119 신고 건수 예측을 통해 실용적 인사이트를 도출하기 위해서는, 다양한 변수 처리가 가능하고 지역적 특성을 반영할 수 있으며, 변수의 중요도를 해석할 수 있는 예측 모델이 필요하다. 이에 본 분석에서는 다양한 변수를 활용하면서도 시계열 예측에 특화된 딥러닝 모델인 **Temporal Fusion Transformer(TFT)**를 예측 모델로 선정하였다.

TFT는 다음과 같은 구조적 강점을 통해 시계열 예측 문제에 뛰어난 성능을 발휘한다.

- Variable Selection Network (VSN) 을 통해 시점별로 중요한 변수만을 동적으로 선택하여 모델의 해석력 향상
- Static Covariate Encoder와 Group Normalizer를 활용해 지역별 고정 특성과 규모 차이를 효과적으로 반영
- Multi-head Attention을 통해 각 시점의 예측에 기여한 요소를 시각적으로 해석할 수 있는 결과 제공

또한, TFT는 LSTM 기반의 인코더를 통해 단기적인 시계열 흐름을 포착하는 동시에, Transformer 구조를 활용해 장기 의존성을 학습할 수 있어, 태풍이나 장마 등 연속적인 기상 이슈나 계절성, 패턴성 등 중장기적 영향 요인을 효과적으로 반영할 수 있다. 이처럼 TFT는 다양한 변수 조합과 시계열 패턴이 복합적으로 작용하는 119 신고 건수 예측에 적합하며, 단순한 수치 예측을 넘어 “어떤 변수 조합이 119 신고와 관련이 있는가”에 대한 정책적 인사이트까지 제공할 수 있는 분석 도구로 활용할 수 있다.

2) 모델링

본 과제는 기상, 인구, 행정, 교통 인프라 등 다양한 외부 요인에 의해 비선형적이고 지역별로 이질적인 119 신고 건수를 예측하는 과제를 수행했다. 이를 위해 시계열 예측에 특화된 TFT 모델을 활용하여 1차 예측을 수행한 뒤, LightGBM 기반의 잔차 보완 모델을 적용하여 예측 성능을 향상시켰다.

가. 예측 모델 [Temporal Fusion Transformer(TFT)]

TFT 모델은 다음과 같은 구조로 구성하였다:

- (1) 과거 7일 데이터를 기반으로 하루 단위 예측 수행 (encoder length = 7, prediction length = 1)
- (2) Static Covariate Encoder를 통해 동 단위 지역 특성 임베딩을 통해 지역별 고정 효과 반영
- (3) Variable Selection Network (VSN) 을 통해 시점별로 유의미한 변수만을 자동으로 선택
- (4) Group Normalizer를 활용해 지역 간 규모 차이 보정
- (5) Multi-head Attention을 통해 예측 시점에 영향을 주는 과거 구간을 학습하여 장기 의존성 반영
- (6) 손실 함수는 RMSE를 사용하였으며, EarlyStopping을 통해 최적 시점을 찾아 학습을 종료

초기에는 Optuna를 이용한 하이퍼파라미터 튜닝을 시도했으나, 과적합으로 인해 검증 시에 오히려 성능이 하락하는 문제가 발생하였다. 따라서 튜닝 이전의 기본 모델을 최종 예측에 활용하였다.

나. 잔차 보완 모델 [LightGBM 회귀 모델]

TFT 모델은 시계열 구조와 변수 간 상호작용을 효과적으로 학습하는 강점을 지니지만, 지역별 미세한 편차나 이상치에 대한 보정력은 제한적일 수 있다. 이를 보완하기 위해, TFT의 예측값과 실제값 간 잔차를 새로운 타겟 변수로 설정하고, 기존 입력 변수들과 TFT 예측값을 함께 활용하여 Gradient Boosting 기반의 LightGBM 회귀 모델을 추가로 학습하였다. 이에 따라 최종 예측값은 아래와 같이 산출하였다.

$$\text{최종 예측값} = \text{TFT 예측값} + \text{LGBM 예측 잔차}$$

이러한 잔차 기반 하이브리드 보완 전략을 통해 모델은 지역별 오차에 대한 대응력과 예외 상황 처리 능력을 강화하였으며, 최종 RMSE를 유의미하게 개선하는 데 기여하였다.

4. 결과 및 검증

최종 검증 결과 **RMSE 0.78**이었다.

아래의 변수 중요도 플롯은 모델이 예측을 수행할 때 어떤 입력 변수가 결과에 얼마나 기여했는지를 시각적으로 보여주는 막대그래프이다. 막대가 길수록 해당 변수의 중요도가 상대적으로 높음을 의미하며, 해당 변수가 예측 오차를 줄이는 데 크게 기여했음을 의미한다. 이를 통해, 모델이 119 신고 건수를 예측함에 있어서 의존한 위험 요인을 직관적으로 파악할 수 있다. 최종 모델에서 위험 요인으로 파악된 변수들에 대하여 다음과 같이 해석할 수 있다.

신고 건수 예측에 가장 크게 기여한 변수는 ta_max_min(일교차)이다. 낮과 밤의 기온 차가 클수록 급격한 일사량 및 기압 변화가 발생하여 열 스트레스, 교통사고, 실외 활동 중 탈진 위험이 동시에 증가하므로 구조·구급 수요가 급등할 가능성이 높아진다. 더 나아가, 높은 일교차로 인해 발생하는 높은 습도차는 불쾌지수 상승과 강수 현상의

주요 원인이 될 수 있다.

두 번째로 중요도가 높게 측정된 time_idx(장기 추세 지표)는 시간의 흐름에 따라 변화하는 변수들의 추세를 포착하고 조정하는 역할을 하여 중요도가 높게 측정되었고, is_rain_cont(강수 지속)는 장기적으로 지속되는 강수 현상으로 인한 침수·도로 통제·고립 상황 및 사고 발생 확률의 증가를 포착하기 때문에 중요도가 높게 측정되었다고 해석할 수 있다.

이어서, 구급기타_mean(month)(월평균 구급기타 신고) 변수는 코로나 확진자 수의 변화와 일치하는 분포를 보여 지역 및 계절별 코로나 영향력의 감소를 효과적으로 포착함으로써 예측 성능 향상에 기여했으며, 65세 이상 인구가 여름철에 발생하는 사고의 주요 위험 대상인 것으로 확인되었다. 이외에도 ta_min(최저기온)과 hm_min(최저습도)는 야간에 기온이 크게 떨어지거나 공기가 건조해지는 조건에서 저체온증, 난방 기구 관련 화재, 호흡기 증상 악화 등으로 신고가 증가할 수 있다는 점을 반영하여 변수 중요도가 높게 나온 것으로 해석할 수 있다.




그림 3. 예측 모델 변수 중요도 결과

5. 결론 및 활용방안

본 연구는 기상, 인구, 도시 인프라 등 외부 요인을 융합한 시계열 기반 분석을 통해, 부산광역시 법정동 단위의 119 신고 건수를 정밀 예측하는 TFT 기반 모델을 구축하였다. 예측 성능(RMSE 0.78)은 실무 활용이 가능한 수준이며, 지역별 변수 해석과 리스크 식별이 가능하다는 점에서 정책적 확장성도 입증되었다. 이 모델은 아래와 같은 방식으로 실질적 활용이 가능하다.

가. 119 신고 리스크 맵 구축 및 자원 재배치 전략 수립: 동별 신고 예측값과 인구를 고려한 1인당 위험도를 시각화함으로써, 고위험 지역을 직관적으로 파악할 수 있다. 이러한 리스크 지도는 지역별 신고 수요를 가시화할 뿐 아니라, 소방서, 119안전센터 등 공급 기반 인프라 정보와 결합하여 자원 배치의 불균형 여부를 진단하고, 공급-수요 간 격차를 최소화하는 재배치 전략 수립에 활용될 수 있다.

나. 기상 연동 기반 지능형 사전 경보 시스템 구축: 기상 예보 데이터를 모델에 실시간으로 연동하면, 향후 1~3일 뒤의 단기 신고 건수 급증 가능성을 사전에 예측할 수 있다. 이 기능을 통해 외부 요인에 따른 수요 변동을 조기에 감지하고, 지능형 사전 경보 시스템으로 발전시킬 수 있다. 예보 기반의 선제 대응은 자원 낭비를 줄이고 현장 대응력을 높이는 데 기여한다.

다. 전국 단위 확장 및 타 분야 전이 가능성: 본 분석 체계는 지역 단위 응급 신고 예측에 최적화된 구조로, 다른 광역시·도 또는 전국 단위로 확장 적용이 가능하다. 또한, 병상 수요 예측, 교통사고 대응 모델링, 도시 재난 대응 체계 수립 등 유사한 구조의 공공 정책 과제에도 전이 활용 가능한 프레임워크를 제공한다.

결론적으로, 본 연구는 단순한 딥러닝 모델 개발을 넘어, 데이터 기반의 응급 대응 전략 수립과 자원 운영 체계의 과학화를 동시에 실현할 수 있는 종합 분석 체계를 제안하였다. 특히 예측 결과가 해석 가능하고 실무 적용이 용이하다는 점에서 정책 결정과 현장 운영 모두에 실질적인 기여가 가능하며, 시민 안전 확보와 행정 효율성 제고에 실질적으로 기여할 수 있다.

참고문헌

- Bryan Lim;Sercan O. Arik;Nicolas Loeff;Tomas Pfister(2019), Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting, arXiv:1912.09363.
- Porto, Bruno Matos;Fogliatto, Flavio Sanson(2024), Enhanced forecasting of emergency department patient arrivals using feature engineering approach and machine learning, *BMC Medical Informatics and Decision Making*, 24(1), Article number:377.
- 안세혁 · 이주언 · Adnan Md Tayeb · 김태형(2022), 공간적 인접성을 고려한 TFT 모델 기반 교통사고 예측, **한국정보과학회 2022 한국컴퓨터종합학술대회 논문집**, 2021-2023쪽.
- 이달별(2020), 구급서비스의 지역 불균형: 부산시 119 구급활동일지 분석, **한국지리정보학회지 제 23권 제3호**, 161-173쪽.
- 이달별(2020), 기상요인이 119 구급서비스에 미치는 영향: 부산을 중심으로, **한국방재학회논문집 제20권 제6호**, 93-100쪽.

활용데이터

- 2024년 해수욕장 개폐장 일정 및 현황(2024), 해양수산부, <https://www.mof.go.kr/doc/ko/selectDoc.do?docSeq=57816&menuSeq=427&bbsSeq=2>.
- 국토교통부_지오코더 API, 공공데이터포털, <https://www.data.go.kr/data/15101106/openapi.do?recommendDataYn=Y>.
- 기상청 API 허브(2020~2024), <https://apihub.kma.go.kr/>.
- 부산광역시 소방재난본부 일반현황(2025), <https://119.busan.go.kr/fsastatus>.
- 부산광역시_구군 행정기관현황(2024), 공공데이터포털, <https://www.data.go.kr/data/15084225/fileData.do>.
- 부산광역시_도로구간조서(2025), 공공데이터포털, <https://www.data.go.kr/data/15116487/fileData.do>.
- 부산광역시_도시공간정보시스템 터널 현황(2025), 공공데이터포털, <https://www.data.go.kr/data/15080572/fileData.do>.
- 부산광역시_종합병원 현황(2025), 공공데이터포털, <https://www.data.go.kr/data/15083386/fileData.do>.
- 부산광역시_지하차도 현황(2024), 공공데이터포털, <https://www.data.go.kr/data/15119688/fileData.do>.
- 부산광역시_해수욕장 방문 현황(2020~2024), 공공데이터포털, <https://www.data.go.kr/data/15043252/fileData.do>.
- 연령 및 성별 인구 - 읍면동(2020~2024), KOSIS, https://kosis.kr/statHtml/statHtml.do?sso=ok&returnurl=https%3A%2F%2Fkosis.kr%3A443%2FstatHtml%2FstatHtml.do%3Flist_id%3DA11_2015_1_10_10%26obj_var_id%3D%26seqNo%3D%26tblId%3DDDT_1IN1503%26vw_cd%3DMT_ZTITLE%26orgId%3D101%26path%3D%252FstatisticsList%252FstatisticsListIndex.do%26conn_path%3DMT_ZTITLE%26itm_id%3D%26lang_mode%3Dko%26scrId%3D%26.
- 질병관리청_코로나19 시군구별 월별 확진자 및 사망 발생 현황(2020~2023), 공공데이터포털, <https://www.data.go.kr/data/15124288/fileData.do>.
- 행정기관(행정동) 및 관할구역(법정동) 코드 변경내역 알림(2025), 행정안전부, https://www.mois.go.kr/frt/bbs/type001/commonSelectBoardArticle.do?bbsId=BBSMSTR_000000000052&nttlId=118483.